



Université Alioune Diop
L'Excellence est ma constance, l'Éthique ma vertu !

UFR Sciences & Technologies - Master 2 Data Science & Genie Logiciel (DSGL)

Année universitaire 2025-2026

PROJET TUTOIRE BIG DATA & IA

Teranga-SN

Intelligence Touristique & Economie Numerique

Tourisme & E-commerce Local - Senegal

NiFi | Kafka | Spark Streaming | HBase | Hive | Airflow | MLflow | Privacy by Design | NLP FR/EN/VO

Etudiant 1	TINE Abdoussalam abdoussalamtine4@gmail.com
Etudiant 2	NDIAYE Papa Malick njaymika@gmail.com
Enseignant	Mr Ahmed Ben Sidy Bouya SEYE Senior Big Data & AI Engineer - Groupe Sonatel

Depot GitHub : github.com/sunulabo/uadb-m2-teranga-sn | Juin 2026

1. Contexte et Objectifs

1.1 Contexte

Teranga signifie hospitalité en Wolof. Ce projet s'inscrit dans la Stratégie Sénégal Numérique 2025-2035 et le Plan Sénégal Emergent, dont l'un des axes est d'atteindre 3 millions de touristes par an à l'horizon 2035. Face à la dispersion des avis touristiques sur TripAdvisor, Google et les plateformes locales (Expat-Dakar, Jumia), et à l'absence d'un tableau de bord unifié pour la Direction Générale du Tourisme (DGTT), Teranga-SN construit un pipeline Big Data temps réel qui collecte, analyse et visualise ces données hétérogènes, tout en garantissant la protection des données personnelles (Privacy by Design).

1.2 Objectifs techniques

#	Composant	Description
1	Ingestion multi-sources	Avis TripAdvisor/Google, arrivées DGTT, flux Jumia/Expat-Dakar
2	NLP multilingue	Analyse sentiment FR/EN/VO par destination et type d'activité
3	Prediction ML	Prediction des pics de fréquentation touristique par destination et mois
4	Privacy by Design	Anonymisation SHA-256, 0 PII dans HBase/Hive
5	Dashboard DGTT	Carte satisfaction touristique, tendances e-commerce, alertes réputation

1.3 Destinations couvertes


Destination	Type	Activités principales
DAKAR	Capitale	Culture, gastronomie, artisanat (marché Sandaga)
SAINT-LOUIS	Patrimoine UNESCO	Architecture coloniale, festival de jazz, fleuve
SALY	Station balnéaire	Plage, resort, sports nautiques
CAP SKIRRING	Ecotourisme	Nature préservée, plongée, Casamance
CASAMANCE	Biodiversité	Mangroves, forêts, pêche artisanale
TOUBA	Pèlerinage	Grand Magal, tourisme religieux mouride
ZIGUINCHOR	Artisanat	Gastronomie locale, marchés artisanaux

1.4 Saisonnalité

Le Sénégal connaît une forte saisonnalité : la haute saison (novembre à mars) correspond à l'hiver européen et concentre ~65 % des arrivées annuelles. La basse saison (mai à octobre) correspond à l'hivernage. Cette contrainte est intégrée dans le simulateur de données et le modèle de prédiction Random Forest.

2. Architecture Technique

2.1 Vue d'ensemble



2.2 Infrastructure Docker - 8 services

Service	Image	Port(s)	Role
Zookeeper	confluentinc 7.4.0	2181	Coordination Kafka
Kafka	confluentinc 7.4.0	9092 / 9093	Bus de messages, retention 72h
Apache NiFi	apache/nifi 1.23.2	8081	Ingestion & routage des flux
HBase	dajobe/hbase 2.1	16010 / 9090	Stockage NoSQL alertes & avis
Hive	apache/hive 3.1.3	10000	Catalogue analytique SQL
Spark Master	bitnami/spark	8080 / 7077	Orchestration Streaming
Spark Worker	bitnami/spark	-	2 coeurs, 2 Go RAM
Airflow	apache/airflow 2.7.3	8082	Orchestration MLOps hebdomadaire

2.3 Flux de données

Le simulateur `kafka_producer_teranga_sn.py` génère toutes les 3 secondes des avis touristiques (FR/EN/WO avec PII), des transactions e-commerce et des arrivées DGTT (toutes les 5 iterations). Ces messages sont envoyés vers deux topics Kafka distincts. Spark Structured Streaming applique : (1) la Privacy Layer (SHA-256 + drop PII), (2) le scoring NLP (lexique 50+ termes), (3) l'agregation en fenêtre glissante 7 jours par destination. Les alertes ROUGE/ORANGE sont publiées sur `teranga_alerts` et persistées dans HBase.

3. Implementation

S1 - Infrastructure & Simulateur

Mise en place de l'infrastructure Docker complete (8 services) et developpement du simulateur `kafka_producer_teranga_sn.py`. Donnees realistes : 10 nationalites (SN, FR, MA, CI, GN, US, DE, IT, ES, GB), 7 destinations, corpus d avis FR/EN/VO. Tables HBase creees via `hbase_setup.py`, schema Hive via `hive_setup.sql`.

- 3 sources : avis touristiques, transactions e-commerce, arrivees DGT
- 2 topics Kafka : `teranga_avis_raw`, `teranga_arrivees_raw`
- 3 tables HBase : `avis_analyses`, `alertes_reputation`, `stats_ecommerce`
- 2 vues Hive analytiques : `vue_destinations`, `vue_ecommerce`

S2 - Streaming NLP & Privacy by Design

Le pipeline Spark Structured Streaming implemente deux mecanismes de protection conformement au RGPD : anonymisation SHA-256 avec sel cryptographique (variable d environnement `TERANGA_SECRET_SALT` obligatoire - arret si absente), drop immediat des colonnes `user_id` et `email_client`. Le lexique de sentiment couvre 50+ termes en trois langues. L agregation par fenetre glissante de 7 jours calcule la reputation de chaque destination : VERT (>0.0), ORANGE (-0.3 a 0.0), ROUGE (<-0.3).

- `SHA-256(user_id + sel) -> user_secure` : stable pour detecter les recidives
- Validation Pandera : refuse tout DataFrame contenant des colonnes PII
- Wolof : `dafa baax lool` (+0.95), `rafet` (+0.80), `dafa neka` (-0.80), `amul solo` (-0.70)
- Fenetre glissante 7j (slide 1j) -> statut VERT / ORANGE / ROUGE par destination

S3 - Modele ML & DAG Airflow MLOps

Random Forest Regressor (150 arbres, profondeur max 10) entraine sur 5 000 observations simulees integrant la saisonnalite reelle du Senegal. Variables categorielles encodees par LabelEncoder. Experiences tracees dans MLflow. Le DAG Airflow s execute chaque lundi a 7h00 et declenche le reentrainement automatique si plus d une destination est en statut ROUGE.

- `RMSE = 31.23` touristes/jour, `R2 = 0.90`, `CV R2 = 0.8989`
- `BranchPythonOperator` : branche `retrain_model` si `n_rouge > 1`
- `spark-submit` automatique vers `spark://spark-master:7077`
- Rapport JSON hebdomadaire genere dans `/opt/models/rapports/`

S4 - Dashboard, Tests & Rapport

Application Flask avec dashboard Bootstrap 5 : 7 cartes destinations, KPI summary (nb VERT/ORANGE/ROUGE), carte Folium interactive et API `/predict` avec validation complete des entrees. Suite de 23 tests automatises executes par GitHub Actions.

- 23 tests pytest : 12 Pandera (schemas + PII + SHA-256 hex) + 11 NLP
- Lexique centralise dans `scripts/lexique.py` - source unique importee partout
- CI GitHub Actions : tests lances a chaque commit sur main / dev-*

- API POST /predict : validation complete, gestion des erreurs 400/422

4. Resultats

4.1 Metriques du modele Random Forest

31.23	0.90	0.8989
RMSE (touristes/jour)	R2 - jeu de test	CV R2 - validation croisee 5 folds

Le modele predit le flux touristique journalier avec une erreur moyenne de +/-31 touristes. Il explique 90 % de la variance observee sur le jeu de test (1 000 observations). La stabilite est confirmee par la validation croisee 5-fold (CV R2 = 0.8989). Les variables les plus determinantes sont le mois (saisonnalite), la destination (popularite) et le score de sentiment.

4.2 Couverture des tests

Suite de tests	Nombre	Resultat
test_schemas.py - Pandera	12	OK - 12 passes
test_streaming.py - NLP	11	OK - 11 passes
Total	23	23/23 - 0 warnings

4.3 Captures d ecran




Fig. 1 - Template NiFi Eq.12 : 4 processors actifs, 2 topics visibles




Fig. 2 - Dashboard web : 7 destinations avec statuts et API prediction




Fig. 3 - DAG teranga_sn_monitoring avec BranchPythonOperator et run reussi

[CAPTURE — Spark Streaming - Console]

```
PS C:\Users\HP\Desktop\Teranga-SN> python scripts/demo_streaming_output.py
=====
Teranga-SN | Spark Structured Streaming | Pipeline NLP FR/EN/WO
=====

Batch 1 | 17:46:27 | topic: teranga_avis_raw

-----
destination : CASAMANCE      langue : FR
note        : 1.5 sentiment_score : +0.0000 [NEUTRE]
user_secure : 7f66a5965dcec580b9695aaa794e0850...
PII drop    : email_client=DROPPED user_id=DROPPED

destination : DAKAR          langue : EN
note        : 4.2 sentiment_score : +0.0000 [NEUTRE]
user_secure : bdb6e9b5070ec67749150f648e2e70ac...
PII drop    : email_client=DROPPED user_id=DROPPED

destination : DAKAR          langue : FR
note        : 4.5 sentiment_score : +1.0000 [POSITIF]
user_secure : 2b91b21f26375d69072dcca2f93581f8...
PII drop    : email_client=DROPPED user_id=DROPPED

destination : TOUBA          langue : FR
note        : 5.0 sentiment_score : +0.0000 [NEUTRE]
user_secure : 3e050e6a95889888f24637388679b3aa...
PII drop    : email_client=DROPPED user_id=DROPPED
```

Fig. 4 - Avis anonymisées avec sentiment_score et user_secure (SHA-256)

[CAPTURE — Alerte HBase - :16010]

APACHE HBASE

Accueil Détails du tableau Procédures et Serrures Métriques de processus Journaux locaux Niveau logarithmique Débogage de débogue Dump des métriques

HBase Configuration

Tableaux

Tables utilisateurs Tables système Instantanés

3 tables dans l'ensemble. [Détails]

Espace de noms	Nom	État	Régions								Description
			OPEN	OUVERTURE	FERMÉ	CLÔTURÉ	HORS LIGNE	ÉCHEC	SÉPARATION	Autres	
Teranga	alertes_reputation	ACTIVÉ	1	0	0	0	0	0	0	0	'teranga :alertes_reputation', {NAME => 'alerte', BLOOMFILTER => 'AUCUN NON', BLOCKCACHE => 'false'}
Teranga	avis_analyses	ACTIVÉ	1	0	0	0	0	0	0	0	'teranga :avis_analyses', {NAME => 'geo', BLOOMFILTER => 'AUCUN NON', BLOCKCACHE => 'faux'}, {NOM => 'méta', BLOOMFILTER => 'AUCUN NON', BLOCKCACHE => 'faux'}, {NOM => 'sentiment', BLOOMFILTER => 'AUCUN NON', BLOCKCACHE => 'faux'}

Fig. 5 - Table teranga:alertes_reputation avec destination ROUGE

[CAPTURE — Dashboard Matplotlib]

Teranga-SN - Tableau de Bord Intelligence Touristique & E-commerce
DGTG Senegal | 13/06/2026 17:53 | Mode : Demonstration




Fig. 6 - 4 graphiques : satisfaction, % positif/negatif, CA e-comm, heatmap

[CAPTURE — Pytest - 23 tests]

```
PS C:\Users\HP\Desktop\Teranga-SN> pytest tests/ -v
===== test session starts =====
platform win32 -- Python 3.13.3, pytest-9.0.2, pluggy-1.6.0 -- C:\Users\HP\AppData\Local\Programs\Python\Python313\python.exe
cachedir: .pytest_cache
rootdir: C:\Users\HP\Desktop\Teranga-SN
plugins: typeguard-4.5.1
collected 23 items

tests/test_schemas.py::test_avis_valide PASSED [ 4%]
tests/test_schemas.py::test_avis_note_superieure_a_5 PASSED [ 8%]
tests/test_schemas.py::test_avis_note_inferieure_a_1 PASSED [ 13%]
tests/test_schemas.py::test_avis_destination_inconnue PASSED [ 17%]
tests/test_schemas.py::test_avis_pii_user_id_detecte PASSED [ 21%]
tests/test_schemas.py::test_avis_pii_email_detecte PASSED [ 26%]
tests/test_schemas.py::test_avis_sentiment_label_invalide PASSED [ 30%]
tests/test_schemas.py::test_avis_user_secure_non_hexadecimal PASSED [ 34%]
tests/test_schemas.py::test_ecomm_valide PASSED [ 39%]
tests/test_schemas.py::test_ecomm_montant_negatif PASSED [ 43%]
tests/test_schemas.py::test_ecomm_categorie_inconnue PASSED [ 47%]
tests/test_schemas.py::test_ecomm_pii_user_id_detecte PASSED [ 52%]
tests/test_streaming.py::test_texte_vide_retourne_zero PASSED [ 56%]
tests/test_streaming.py::test_avis_positif_fr PASSED [ 60%]
tests/test_streaming.py::test_avis_negatif_fr PASSED [ 65%]
tests/test_streaming.py::test_avis_positif_en PASSED [ 69%]
tests/test_streaming.py::test_avis_negatif_en PASSED [ 73%]
tests/test_streaming.py::test_avis_positif_wolof PASSED [ 78%]
tests/test_streaming.py::test_avis_negatif_wolof PASSED [ 82%]
tests/test_streaming.py::test_avis_neutre PASSED [ 86%]
tests/test_streaming.py::test_score_dans_intervalle PASSED [ 91%]
tests/test_streaming.py::test_casse_insensible PASSED [ 95%]
tests/test_streaming.py::test_lexique_wolof_enrichi PASSED [100%]

===== 23 passed in 1.19s =====
```

Fig. 7 - 23 passed in ~1.2s - 0 warnings

5. Tableau de Conformite au Bareme

Critere	Pts	Niveau	Elements de preuve
Ingestion NiFi Multi-Sources	3 pts	Excellent	3 sources, 2 topics, FR/EN/WO, template XML

Validation & Privacy	4 pts	Excellent	Pandera + SHA-256 hex + drop PII + 0 PII HBase
NLP Sentiment & Streaming	6 pts	Excellent	Lexique 50+ termes FR/EN/WO, fenetre 7j, watermark
Prediction Flux & MLOps	4 pts	Excellent	RF RMSE 31.23 / R2 0.90 + DAG hebdo + MLflow
Dashboard DGTT & Reputation	3 pts	Excellent	Carte Folium, alertes ROUGE, top e-comm, Flask
Bonus README + docstrings FR	+0.5	OK	docker compose up + commentaires dans tous les scripts
Bonus Tests pytest	+0.5	OK	23 tests (12 Pandera + 11 NLP) + CI GitHub Actions
Bonus Demo HBase live	+0.5	A demontrer	Alerte ROUGE visible en soutenance

6. Conclusion et Perspectives

6.1 Bilan technique

Le projet Teranga-SN a abouti a un systeme Big Data fonctionnel couvrant l'integralite de la chaine de valeur : de l'ingestion multi-sources temps reel jusqu'a un dashboard interactif accessible via navigateur, en passant par un pipeline Spark, un modele de prediction touristique et un cycle MLOps automatise. Les livrables des 4 semaines sont complets et conformes aux exigences du sujet.

6.2 Contributions cles

- Privacy by Design : SHA-256 + sel cryptographique (variable d'environnement), validation Pandera avec controle d'absence de PII - aucune donnee personnelle n'atteint HBase/Hive
- NLP trilingue : premier lexique de sentiment Wolof adapte au tourisme senegalais (teranga, dafa baax, dafa neka) - 50+ termes FR/EN/WO
- MLOps : detection automatique de derive de reputation et reentrainement conditionnel via Airflow BranchPythonOperator, traçabilité MLflow
- Qualite logicielle : 23 tests automatises, integration continue GitHub Actions, lexique centralise, architecture modulaire

6.3 Limites identifiees

- Modele entraine sur donnees synthetiques - $R^2 = 0.90$ refilete la capacite a reproduire une formule connue plutot qu'une performance sur donnees reelles
- Lexique NLP lexical (regles) - une approche neuronale (AfriBERT, Wolof-BERT) ameliorerait la precision sur les formulations ambiguës
- Dashboard Flask avec donnees simulees en l'absence d'un pipeline Spark actif

6.4 Perspectives d'evolution

- Connexion aux APIs TripAdvisor et DGTT pour des donnees reelles
- Integration d'un modele NLP base sur AfriBERT ou Wolof-BERT
- Deploiement cloud (AWS EMR ou Google Dataproc) pour passage a l'echelle nationale
- Interface de reporting PDF automatique hebdomadaire envoyee a la DGTT via Airflow

6.5 Apports personnels

Ce projet nous a permis d'acquiere une maitrise pratique des outils du Big Data industriel (Kafka, Spark Streaming, HBase, Hive, Airflow) et d'appréhender les enjeux de la protection des donnees personnelles dans un contexte africain. La dimension multilingue - integrer le Wolof dans un pipeline NLP - est particulierement significative : elle temoigne de la faisabilite d'une intelligence artificielle ancree dans les realites linguistiques locales du Senegal.

"Always be a solution, never a problem."